HAI930I - Systèmes multi-agents
Tournoi d'Axelrod : un LLM auto-adaptatif (MAPE-K) face à des stratégies déterministes

Dejean Robin, Hafdane Léo, Texier-Grailhes Killian

Novembre 2026

1 Introduction

Le projet reproduit le tournoi d'Axelrod sur le dilemme du prisonnier itéré (gains : 3/3 si les deux coopèrent, 1/1 si les deux trahissent, 5/0 pour celui qui trahit un coopérateur). Un joueur piloté par un LLM y affronte neuf stratégies déterministes classiques. À chaque round, le LLM joue selon une *stratégie de prompt* (Generous, Pragmatic, Merciless ou Peacemaker). Tous les `mapek_every` rounds, une boucle MAPE-K (Monitor, Analyze, Plan, Execute, Knowledge) peut changer cette stratégie.

La question posée par le sujet est la suivante : **un LLM auto-adaptatif peut-il remonter au score (« comeback ») quand il détecte qu'il joue mal ?**

2 Paramètres testés

2.1 Données

Les matchs ont été produits avec le générateur de données du programme, à partir de deux fichiers d'historique : `results_history.jsonl` (Killian) et `results_history_robin.jsonl` (Robin). Le script `sort_history.py` les a réunis puis rangés par condition expérimentale. Les matchs rejoués à l'identique lors d'une relance ont été mis de côté (60 matchs). Il reste **672 matchs** : 668 en 1 contre 1 et un tournoi de 4 matchs, répartis en 17 conditions.

2.2 Variables étudiées

Paramètre	Valeurs testées	Rôle
`adaptive`	oui / non	boucle MAPE-K active, ou stratégie de départ conservée tout le match (référence *figée*)
`mapek_every`	1, 5, 10	la boucle tourne tous les N rounds
`turns`	10, 20	nombre de rounds par match
`window`	1, 5, 10, 20	fenêtre glissante de l'étape Monitor (en rounds)
`temperature`	0,1, 0,2, 0,9	température d'échantillonnage du LLM
`repetitions`	1, 5	nombre de matchs par combinaison
stratégie de départ	4	Generous, Pragmatic, Merciless, Peacemaker
adversaire	9	Cooperator, Defector, Tit For Tat, Tit For 2 Tats, Suspicious Tit For Tat, Grudger, Alternator, Prober, Win-Stay Lose-Shift

Table 1 – Paramètres que nous avons fait varier.

Les autres réglages sont restés fixes : seuil « POOR » à 1,5 point par round, 10 rounds d'historique montrés au LLM, graine aléatoire 1.

Nombre de cycles MAPE-K. Un match de T rounds avec une période N compte $\lfloor (T-1)/N \rfloor$ cycles MAPE-K :

- 10 rounds avec $N = 10$: **0 cycle**. La boucle ne tourne jamais et ces matchs sont en réalité figés ;
- 10 rounds avec $N = 5$: 1 seul cycle, au round 5 ;
- 20 rounds avec $N = 5$: 3 cycles ;
- 10 rounds avec $N = 1$: 9 cycles (un par round).

Le modèle n'est pas un paramètre. Plusieurs modèles ont joué : gemma-4-26b (399 matchs), gemini-3.1-flash-lite (146) et gemini-3.5-flash-lite (116), plus quelques autres. Nous changions de modèle pour contourner les quotas gratuits, ce n'était pas un choix expérimental. Nous supposons donc que tous les modèles se valent ; la section 3.9 discute cette hypothèse.

2.3 Conditions jouées

Rounds	Temp.	Rép.	MAPE-K	Fenêtre	Adversaires	Matchs	Données
10	0,1	1	figé	5	9	42	Killian
10	0,1	1	5	5	9	67	Killian
10	0,1	1	10	5	2	8	Killian
10	0,2	1	figé	5	9	80	Killian, Robin
10	0,2	1	1	5	5	26	Robin
10	0,2	1	5	5	9	63	Killian, Robin
10	0,2	1	10	5	1	2	Killian
10	0,2	5	figé	5	6	105	Killian
10	0,2	5	5	5	6	116	Killian
10	0,9	1	figé	5	9	41	Killian
10	0,9	1	5	5	9	64	Killian
10	0,9	1	10	5	2	8	Killian
20	0,2	1	5	1	3	12	Robin
20	0,2	1	5	5	3	12	Robin
20	0,2	1	5	10	3	11	Robin
20	0,2	1	5	20	3	11	Robin

TABLE 2 – Les conditions en 1 contre 1 (la 17e est un tournoi à 5 joueurs : 10 rounds, T = 0,2, MAPE-K tous les 10 rounds, donc jamais ; 4 matchs du LLM, Killian). Chaque condition croise ses adversaires avec les 4 stratégies de départ. Les matchs de 20 rounds opposent le LLM à Cooperator, Defector et Tit For Tat ; ceux avec $N = 1$ à ces trois adversaires plus Tit For 2 Tats et Suspicious Tit For Tat.

2.4 Métriques

- **Score moyen par round** du LLM (entre 0 et 5), le critère principal. Pour comparer deux modes à armes égales, on fait d'abord la moyenne de chaque cellule (adversaire × stratégie de départ), puis on compare les cellules deux à deux.
- **Issue** du match (victoire, nul, défaite) et **taux de coopération**.
- **Comeback** : moyenne des 5 premiers rounds sous 1,5 point par round (seuil « POOR »), et moyenne des 5 derniers rounds supérieure d'au moins 0,5 point. On utilise une fenêtre de 5 rounds pour toutes les conditions, afin qu'elles restent comparables.
- **Changements de stratégie** décidés par la boucle, et **stratégie finale**.

3 Résultats

Sauf mention contraire, les résultats portent sur les matchs de 10 rounds à 1 répétition, en comparant la boucle tous les 5 rounds au mode figé (357 matchs, 103 cellules).

3.1 Score moyen : pas de gain global

Température	Figé	Adaptatif	Écart	Cellules meilleures / moins bonnes
0,1	2,37	2,40	+0,03	38 % / 38 %
0,2	2,35	2,34	−0,01	39 % / 25 %
0,9	2,36	2,33	−0,03	36 % / 42 %
Toutes			−0,00	38 % / 35 %

TABLE 3 – Score moyen par round du LLM (moyenne des cellules adversaire × stratégie de départ). Les cellules restantes sont à égalité.

En moyenne, la boucle MAPE-K **ne change pas le score** : l'écart avec le mode figé est nul sur l'ensemble des 103 cellules et reste inférieur à 0,03 point par round à chaque température. Il y a autant de cellules où l'adaptation fait mieux (38 %) que de cellules où elle fait moins bien (35 %). Les expériences à 5 répétitions le confirment : l'écart y est de −0,04 (21 cellules).

3.2 Beaucoup plus de victoires, mais moins de coopération

Mode	Victoires	Nuls	Défaites	Coopération du LLM	Coop. mutuelle	Score adverse
Figé	17 %	58 %	26 %	66 %	49 %	2,52
Adaptatif	47 %	29 %	23 %	49 %	37 %	2,02

TABLE 4 – Issues et comportement (10 rounds, 1 répétition, toutes températures).



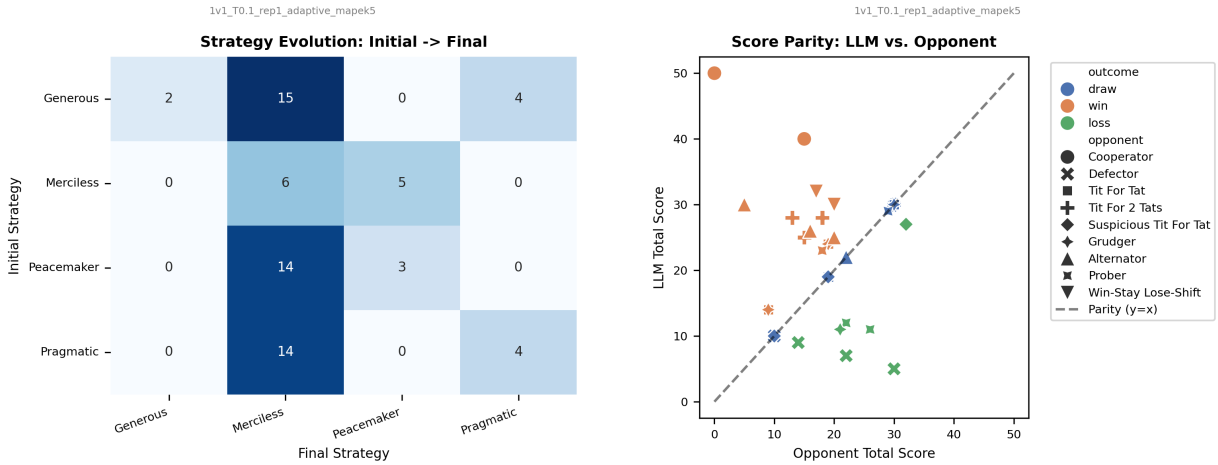
(a) Figé (b) Adaptatif

FIGURE 1 – Issues des matchs, T = 0,2 et 5 répétitions. Attention : les couleurs ne correspondent pas d'un camembert à l'autre, il faut se fier aux étiquettes (*win*, *draw*, *loss*).

Le LLM adaptatif **gagne presque trois fois plus de matchs** (47 % contre 17 %), mais son score ne progresse pas. Il gagne en trahissant davantage : sa coopération passe de 66 % à 49 %.

C'est l'adversaire qui perd des points (de 2,52 à 2,02), pas le LLM qui en gagne. C'est la leçon classique d'Axelrod : *battre* son adversaire n'est pas *marquer beaucoup*. Les nuls à 3 points par round (coopération mutuelle) sont remplacés par des victoires à plus faible score.

3.3 La boucle converge vers Merciless



(a) Stratégie de départ → stratégie finale

(b) Score du LLM contre score adverse

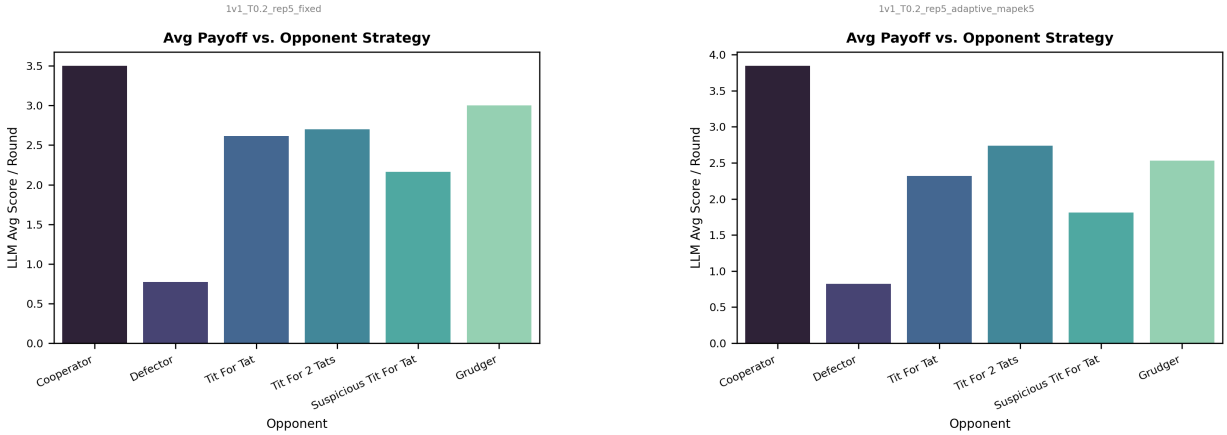
FIGURE 2 – Matchs adaptatifs, T = 0,1, MAPE-K tous les 5 rounds.

Sur l'ensemble des matchs adaptatifs (194 matchs), **68 % finissent en Merciless**, quelle que soit la stratégie de départ (figure 2a). L'étape Plan choisit Merciless contre la plupart des adversaires : de 67 à 90 % des cas contre Cooperator, Alternator, Defector, Grudger, Suspicious Tit For Tat et Win-Stay Lose-Shift. Elle n'est plus mesurée que contre Prober (38 %), Tit For 2 Tats (48 %) et Tit For Tat (50 %). Sur le graphe de parité, les victoires (au-dessus de la diagonale) sont nombreuses, et les nuls à 30–30 (coopération parfaite) se font rares.

3.4 Effet de la boucle selon l'adversaire

Adversaire	Meilleure stratégie figée (score)	Gain de MAPE-K	Finit en Merciless
Cooperator	Merciless (5,00)	+0,48	69 %
Alternator	Merciless (3,00)	+0,20	72 %
Defector	Merciless (1,00)	+0,16	90 %
Win-Stay Lose-Shift	toutes (3,00)	+0,11	86 %
Tit For 2 Tats	Generous, Peacemaker, Pragmatic (3,00)	+0,09	48 %
Tit For Tat	Generous, Peacemaker, Pragmatic (3,00)	−0,15	50 %
Prober	Peacemaker, Pragmatic (2,90)	−0,16	38 %
Suspicious Tit For Tat	Generous (2,68)	−0,24	67 %
Grudger	Generous, Peacemaker, Pragmatic (3,00)	−0,45	85 %

TABLE 5 – Gain moyen de l'adaptatif sur le figé (points par round), par adversaire (10 rounds, 1 répétition, toutes températures).



(a) Figé (b) Adaptatif

FIGURE 3 – Score moyen par adversaire, T = 0,2 et 5 répétitions.

Le tableau 5 sépare deux familles d'adversaires :

— **Adversaires inconditionnels ou exploitables** (Cooperator, Alternator, Defector) : la boucle **aide**. Contre Cooperator, passer à Merciless fait monter les 5 derniers rounds à environ 4,3 points par round. Contre Defector, passer à Merciless arrête l'exploitation et atteint le meilleur score possible (1 point par round).

— **Adversaires qui punissent la trahison** (Grudger, Tit For Tat, Suspicious Tit For Tat, Prober) : la boucle **nuit**. Le cas de Grudger est le plus net. En partant de Generous, le LLM coopère parfaitement pendant 5 rounds (3 points par round), puis l'étape Plan passe quand même à Merciless (5 matchs sur 5). Grudger trahit alors jusqu'à la fin, et la fin de match tombe à 1,8 point par round.

Les mêmes tendances se retrouvent à 5 répétitions (figure 3) : +0,42 contre Cooperator, −0,36 contre Grudger et Suspicious Tit For Tat, −0,30 contre Tit For Tat.

3.5 Le comeback

Mode	Matchs mal commencés	5 premiers rounds	5 derniers rounds	Comeback
Figé	38	0,60	0,61	5 %
Adaptatif	39	0,57	0,99	**46 %**

TABLE 6 – Matchs dont les 5 premiers rounds sont sous 1,5 point par round (10 rounds, MAPE-K tous les 5 rounds, 1 répétition, toutes températures).

Parmi les matchs mal commencés, **46 % se terminent en comeback** avec MAPE-K, contre 5 % sans. Les matchs mal commencés sont presque tous contre Defector (31 sur 39), et **tous** les comebacks observés le sont (18 sur 18). Le LLM, exploité au début, passe à Merciless et finit à 1,0 point par round, le maximum atteignable contre cet adversaire. Le résultat se retrouve à toutes les températures (46 %, 43 % et 50 % de comeback à T = 0,1, 0,2 et 0,9) et à 5 répétitions (40 % contre 20 %).

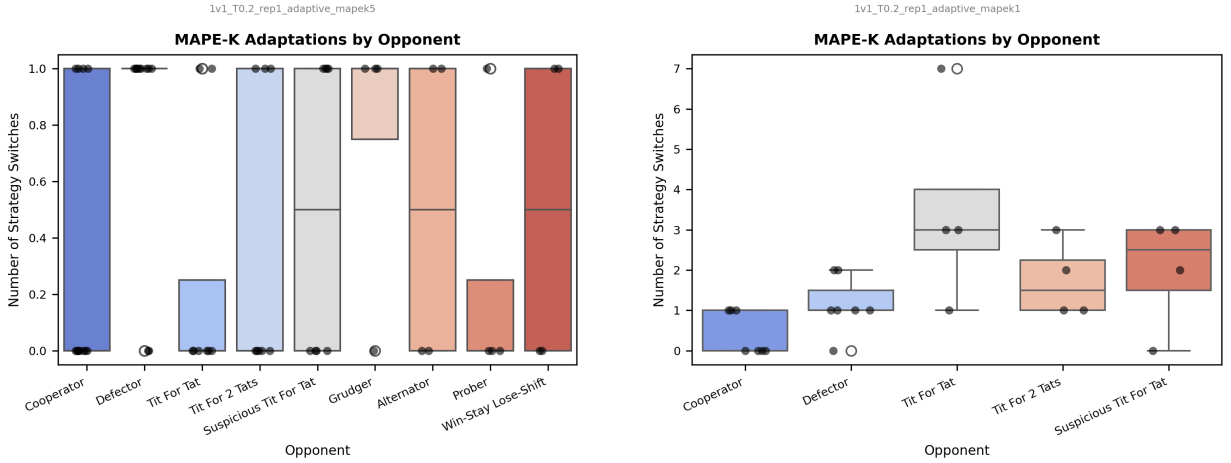
Ce comeback reste **limité en points** : on ne peut pas faire mieux que 1 point par round contre Defector. Le LLM ne « gagne » donc pas ces matchs : il cesse seulement de perdre des points.

3.6 Fréquence de la boucle MAPE-K

Robin a comparé une boucle à chaque round ($N = 1$) à une boucle tous les 5 rounds ($N = 5$) et au mode figé, à T = 0,2, sur les cinq mêmes adversaires.

	Figé	$N = 5$	$N = 1$
Score moyen (cellules)	2,30	2,38	**2,46**
Écart avec le figé		+0,08	+0,16
Changements par match	0	0,47	1,54
Victoires	14 %	26 %	46 %
Coopération du LLM	68 %	56 %	38 %
Cooperator	3,46	3,65	3,89
Defector	0,41	0,72	**0,91**
Suspicious Tit For Tat	2,18	2,05	2,05
Tit For 2 Tats	2,72	2,76	2,75
Tit For Tat	2,62	2,59	2,55

TABLE 7 – Effet de la période MAPE-K (10 rounds, T = 0,2, 1 répétition, 20 cellules). En bas, score moyen par adversaire.



(a) $N = 5$ (9 adversaires)

(b) $N = 1$ (5 adversaires)

FIGURE 4 – Nombre de changements de stratégie par match, selon l'adversaire.

— **Une boucle plus fréquente réagit plus tôt.** Contre Defector, le LLM détecte l'exploitation dès les premiers rounds et marque 0,91 point par round, contre 0,72 avec $N = 5$ et 0,41 en figé. Contre Cooperator, il commence à l'exploiter plus tôt (3,89).
— Ce n'est pas un comeback au sens de notre métrique : avec $N = 1$, la correction intervient *pendant* les 5 premiers rounds. Contre Defector, ceux-ci valent 0,83 point par round avec $N = 1$, contre 0,44 avec $N = 5$: ils passent rarement sous le seuil, et aucun match n'est classé comeback. Le problème est simplement évité plus tôt.
— **Elle rend aussi le LLM instable** contre les stratégies réciproques. Contre Tit For Tat, il change jusqu'à 7 fois de stratégie en 10 rounds (figure 4) et ne fait pas mieux que le mode figé (2,55 contre 2,62). 81 % des matchs avec $N = 1$ finissent en Merciless.
— Ces cinq adversaires ne comptent ni Grudger ni Prober, contre lesquels la boucle nuit le plus : le gain de +0,16 est donc probablement optimiste.
— Avec $N = 10$ et 10 rounds, la boucle ne tourne jamais : les 18 matchs concernés n'ont aucun changement de stratégie.

3.7 Matchs de 20 rounds et taille de la fenêtre

Robin a aussi joué des matchs de 20 rounds (3 cycles MAPE-K), contre Cooperator, Defector et Tit For Tat, avec une fenêtre Monitor de 1, 5, 10 ou 20 rounds.

Fenêtre	1	5	10	20
Matchs	12	12	11	11
Score moyen	2,27	2,15	2,17	2,23
Changements par match	0,75	0,92	0,55	0,73
Finit en Merciless	58 %	58 %	55 %	55 %
Comeback (matchs mal commencés)	2/4	2/4	2/4	2/4
Cooperator	3,50	3,50	3,50	3,50
Defector	0,88	0,88	0,88	0,86
Tit For Tat	2,42	2,08	2,12	2,37

TABLE 8 – Matchs de 20 rounds (T = 0,2, MAPE-K tous les 5 rounds). En bas, score moyen par adversaire.

— **La taille de la fenêtre ne change presque rien** : les scores restent entre 2,15 et 2,27, et les résultats contre Cooperator et Defector sont identiques pour les quatre fenêtres. Seul Tit For Tat varie (de 2,08 à 2,42), mais sur 4 matchs par fenêtre seulement.
— **Plus de cycles ne donne pas plus d'adaptation.** Malgré 3 cycles par match, le LLM change en moyenne moins d'une fois de stratégie. Il n'exploite même plus Cooperator : 3,50 = (5 + 3 + 3 + 3) / 4, ce qui veut dire que seule la stratégie de départ Merciless marque 5 points. Ces matchs ont surtout été joués par gemini-3.1-flash-lite et gemini-3.5-flash-lite (voir la section 3.9).
— Il n'y a pas de matchs figés de 20 rounds pour servir de référence : on ne peut pas mesurer le gain de la boucle sur des matchs plus longs.

3.8 Température, répétitions et reproductibilité

— **Température.** Elle n'a pas d'effet visible sur le score (tableau 3) : de 2,35 à 2,37 en figé, de 2,33 à 2,40 en adaptatif. Le LLM suit les stratégies de prompt de façon très déterministe, même à T = 0,9.
— **Variabilité.** Avec 5 répétitions par combinaison (T = 0,2), en mode figé, seulement 10 % des cellules donnent des scores différents d'une répétition à l'autre (écart-type moyen 0,01). En adaptatif, 50 % des cellules varient (écart-type moyen 0,14). La variabilité vient donc surtout des décisions de l'étape Plan, pas du choix des coups.
— **Reproductibilité entre nous.** Sur les 20 cellules jouées à la fois par Killian et par Robin (T = 0,2), l'écart moyen entre nos deux résultats est de 0,05 point par round en figé (60 % de cellules identiques) et de 0,19 en adaptatif (50 %). Les résultats figés sont donc bien reproductibles d'une machine à l'autre ; les résultats adaptatifs le sont moins.

3.9 Effet du modèle

Modèle	Matchs	Changements par match	Finit en Merciless	Score moyen
gemini-3.1-flash-lite	33	0,30	42 %	2,36
gemini-3.5-flash-lite	58	0,76	83 %	2,35
gemma-4-26b	99	0,77	69 %	2,33

TABLE 9 – Matchs adaptatifs de 10 rounds, MAPE-K tous les 5 rounds, selon le modèle qui a joué.

L'hypothèse « tous les modèles se valent » **tient pour le score** (de 2,33 à 2,36), **mais pas pour le comportement de l'étape Plan** : gemini-3.1-flash-lite change 2,5 fois moins souvent de stratégie que les deux autres modèles et choisit deux fois moins souvent Merciless. Sur 20 rounds, il ne change de stratégie que 0,16 fois par match, contre 0,95 pour gemini-3.5-flash-lite. Comme le

modèle utilisé dépendait des quotas, il est lié à certaines conditions. C'est le cas des matchs de 20 rounds et d'une partie des matchs à T = 0,2.

3.10 Tournoi

Le seul tournoi enregistré (5 joueurs, T = 0,2, départ en Peacemaker) a été joué avec `mapek_every` = 10 : la boucle n'a donc jamais tourné. Le LLM, resté en Peacemaker, finit **4e sur 5** (1,65 point par round). Defector gagne le tournoi (3,30). Peacemaker coopère face à Defector (0 à 50 sur le match) et se fait exploiter par Prober (6 à 46). C'est précisément la situation qu'une boucle MAPE-K active devrait corriger, mais aucun tournoi n'a été joué avec la boucle active.

4 Conclusion

4.1 Réponse à la question

Oui, un LLM auto-adaptatif peut remonter au score quand il détecte qu'il joue mal. Quand le LLM se fait exploiter (par Defector, dans nos expériences), la boucle MAPE-K le détecte et change de stratégie : 46 % des matchs mal commencés se terminent en comeback, contre 5 % sans adaptation. Le LLM atteint alors le meilleur score possible contre cet adversaire. Avec une boucle à chaque round, il réagit encore plus tôt et évite une bonne partie de la perte de points (0,91 point par round contre Defector, au lieu de 0,41 en figé).

Mais ce comeback ne rend pas le LLM meilleur en général. Sur l'ensemble des adversaires, la boucle ne change pas le score moyen (écart de 0,00 point par round). La raison est un **biais marqué de l'étape Plan vers Merciless** (68 % des matchs adaptatifs finissent dans cette stratégie) : le LLM trahit aussi quand tout va bien, ce qui casse la coopération avec les stratégies qui punissent la trahison (Grudger, Tit For Tat, Suspicious Tit For Tat). Il gagne plus de matchs (47 % contre 17 %) mais ne marque pas plus de points. Dans l'esprit du tournoi d'Axelrod, où seul compte le total de points, l'adaptation n'apporte donc pas d'avantage.

Stratégies optimales observées : Merciless contre les adversaires inconditionnels (Cooperator, Defector, Alternator) ; une stratégie coopérative et réciproque (Pragmatic, Peacemaker ou Generous) contre les stratégies qui punissent la trahison. Une boucle idéale devrait donc identifier la famille de l'adversaire et *ne pas* quitter une coopération mutuelle qui fonctionne.

4.2 Limites et pistes

- **Matchs courts.** Avec 10 rounds et une boucle tous les 5 rounds, le LLM ne peut changer de stratégie qu'une fois. Les matchs de 20 rounds n'ont été joués que contre 3 adversaires et sans référence figée.
- **Modèles.** Ils ne se comportent pas pareil dans l'étape Plan, et le modèle utilisé est lié à certaines conditions. Une même série d'expériences devrait être jouée avec un seul modèle.
- **Échantillons.** Avec 1 répétition, chaque cellule ne contient que 1 à 3 matchs : les écarts de quelques centièmes ne sont pas significatifs. Seules les tendances retrouvées dans plusieurs conditions (par famille d'adversaires, comeback contre Defector, biais vers Merciless) sont solides.
- **Tournoi.** Aucun tournoi n'a été joué avec une boucle active.

Pistes. Rendre l'étape Plan plus prudente (ne pas quitter une stratégie qui donne un résultat « GOOD », ou garder la coopération mutuelle comme objectif). Allonger les matchs et ajouter une référence figée de même longueur. Rejouer les tournois avec une boucle active (par exemple tous les 5 rounds sur 30 rounds). Intégrer les résultats de Léo, qui ne figurent pas encore dans ces données.